

HW0526

2026-05-31

16.18

```
library(PoEdata)
library(lmtest)    # 假設檢定
```

```
## Warning: 套件 'lmtest' 是用 R 版本 4.2.3 來建造的
```

```
## 載入需要的套件：zoo
```

```
## Warning: 套件 'zoo' 是用 R 版本 4.2.3 來建造的
```

```
##
## 載入套件：'zoo'
```

```
## 下列物件被遮斷自 'package:base':
##
##      as.Date, as.Date.numeric
```

```
library(sandwich) # 穩健標準誤計算
data("lasvegas", package = "PoEdata")
eq <- delinquent ~ lvr + ref + insur + rate + amount + credit + term + arm
```

a.

```
cat("\n--- (a) Linear Probability Model (LPM) ---\n")
```

```
##
## --- (a) Linear Probability Model (LPM) ---
```

```
lpm_model <- lm(eq, data = lasvegas)

# 使用 White 異質變異穩健標準誤 (HC1 為 Stata 預設，較常用)
lpm_robust <- coeftest(lpm_model, vcov = vcovHC(lpm_model, type = "HC1"))
print(lpm_robust)
```

```
##
## t test of coefficients:
##
##           Estimate Std. Error t value Pr(>|t|)
## (Intercept)  0.68849128  0.22850643   3.0130 0.0026525 **
## lvr          0.00162385  0.00067523   2.4049 0.0163601 *
## ref         -0.05932367  0.02402561  -2.4692 0.0137098 *
## insur       -0.48158489  0.03036944 -15.8575 < 2.2e-16 ***
## rate         0.03437614  0.00981944   3.5008 0.0004845 ***
## amount      0.02376801  0.01445089   1.6447 0.1003398
## credit      -0.00044190  0.00020728  -2.1319 0.0332620 *
## term        -0.01261951  0.00355596  -3.5488 0.0004051 ***
## arm         0.12832392  0.02769325   4.6338 4.07e-06 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

lvr (貸款價值比): 為正LVR 越高代表借款人自有資金越少，違約風險越高 credit (信用分數): 為負，信用分數越高，違約機率越低 rate (初始利率): 為正，利率越高，還款壓力越大，越容易違約

b.

```
cat("\n--- (b) Logit Model ---\n")
```

```
##
## --- (b) Logit Model ---
```

```
logit_model <- glm(eq, data = lasvegas, family = binomial(link = "logit"))
summary(logit_model)
```

```
##
## Call:
## glm(formula = eq, family = binomial(link = "logit"), data = lasvegas)
##
## Deviance Residuals:
##      Min       1Q   Median       3Q      Max
## -2.2139  -0.4346  -0.3239  -0.1611   2.9434
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)  1.665303   1.992157   0.836 0.403195
## lvr          0.013519   0.008199   1.649 0.099164 .
## ref         -0.525064   0.230491  -2.278 0.022725 *
## insur       -3.122105   0.216906 -14.394 < 2e-16 ***
## rate         0.308656   0.082771   3.729 0.000192 ***
## amount       0.217606   0.113769   1.913 0.055786 .
## credit      -0.003564   0.001933  -1.844 0.065232 .
## term        -0.133037   0.034597  -3.845 0.000120 ***
## arm          1.405649   0.371355   3.785 0.000154 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 998.03  on 999  degrees of freedom
## Residual deviance: 666.29  on 991  degrees of freedom
## AIC: 684.29
##
## Number of Fisher Scoring iterations: 5
```

Logit 模型估計出的係數正負號 (Signs) 與顯著性 (Significance/p-value) 會與 (a) 小題的 LPM 一致 但在 Logit 模型中, lvr ($p=0.099$) 和 credit ($p=0.065$) 的 p-value 變大了, 它們在 5% 水準下變成了不顯著, 只能在 10% 的水準下勉強顯著 (報表上標示為 .) 這顯示 Logit 模型對於這兩個變數的估計較為保守

C.

```
cat("\n--- (c) Predictions for 500th and 1000th observations ---\n")
```

```
##
## --- (c) Predictions for 500th and 1000th observations ---
```

```
obs_to_predict <- lasvegas[c(500, 1000), ]

# LPM 預測
lpm_pred_c <- predict(lpm_model, newdata = obs_to_predict)
cat("LPM Predictions:\n"); print(lpm_pred_c)
```

```
## LPM Predictions:
```

```
##      500      1000
## 0.1827828 0.5785296
```

```
# Logit 預測 (加上 type="response" 才會輸出機率，否則會輸出 z 值)
logit_pred_c <- predict(logit_model, newdata = obs_to_predict, type = "response")
cat("Logit Predictions:\n"); print(logit_pred_c)
```


```
## Logit Predictions:
```

```
##          500          1000
## 0.1335848 0.6265535
```

兩個模型在「方向性」上的判斷是一致的：第 1000 位借款人的違約風險遠高於第 500 位 當機率落在中間區域（例如 0.2 ~ 0.8 之間）時，LPM 和 Logit 算出來的數字通常會蠻接近的。可以微幅觀察到 Logit 的特性：對於相對安全的客戶（第500筆），Logit 給的機率比 LPM 更低；對於高風險客戶（第1000筆），Logit 給的機率比 LPM 更高 Logit 比較容易將機率推向兩端

d.

```
hist(lasvegas$credit, main="Histogram of CREDIT", xlab="Credit Score")
```



```
cat("\n--- (d) Probabilities for CREDIT = 500, 600, 700 ---\n")
```

```
##
## --- (d) Probabilities for CREDIT = 500, 600, 700 ---
```

```
# 建立情境資料集
scenario_d <- data.frame(
  credit = c(500, 600, 700),
  amount = 2.5, lvr = 80, rate = 8,
  insur = 0, ref = 0, arm = 0, term = 30
)

# 預測機率
prob_lpm_d <- predict(lpm_model, newdata = scenario_d)
prob_logit_d <- predict(logit_model, newdata = scenario_d, type = "response")

results_d <- data.frame(CREDIT = c(500, 600, 700), LPM_Prob = prob_lpm_d, Logit_Prob = prob_logit_d)
print(results_d)
```

```
##   CREDIT  LPM_Prob Logit_Prob
## 1    500 0.5532956 0.4967030
## 2    600 0.5091060 0.4086308
## 3    700 0.4649165 0.3260580
```

LPM 機率：0.553 (500分) → 0.509 (600分) → 0.465 (700分) 每增加 100 分，機率固定下降約 0.044 (4.4%)
 Logit 機率：0.497 (500分) → 0.409 (600分) → 0.326 (700分) 下降幅度是變動的（先降 0.088，再降 0.083）兩者都顯示「信用分數越高，違約機率越低」最大的差異在於形狀：LPM 是一條直線，所以分數每進步 100 分，機率下降的幅度是「等差」的 但 Logit 模型是一條 S 型曲線，它捕捉到了非線性關係。因為在 500 分時，預測機率 (0.497) 最接近 0.5（曲線最陡峭的地方），所以此時分數提升帶來的機率降幅最大

e.

```
cat("\n--- (e) Marginal Effect of CREDIT ---\n")
```

```
##
## --- (e) Marginal Effect of CREDIT ---
```

```
# LPM 的邊際效應永遠是固定的 (即 credit 的迴歸係數)
me_lpm <- coef(lpm_model)["credit"]

# Logit 的邊際效應會隨條件改變: ME = P * (1 - P) * Beta
beta_credit_logit <- coef(logit_model)["credit"]
me_logit_d <- prob_logit_d * (1 - prob_logit_d) * beta_credit_logit

results_e <- data.frame(CREDIT = c(500, 600, 700), LPM_ME = rep(me_lpm, 3), Logit_ME = me_logit_d)
print(results_e)
```


```
##   CREDIT      LPM_ME      Logit_ME
## 1    500 -0.0004418953 -0.0008910620
## 2    600 -0.0004418953 -0.0008613439
## 3    700 -0.0004418953 -0.0007832567
```

LPM 的邊際效應在任何分數下都是一個常數，意味著不管信用是極差的 300 分，還是極好的 800 分，進步 1 分的效果永遠一樣，這不符合現實

Logit 的邊際效應是動態的。信用極差（500）或極好（700）時，邊際效應通常較小；而在臨界邊緣（例如機率靠近 0.5 附近）時，邊際效應最大，這反映了現實：對於信用已經很好的人，再增加一點分數，對降低違約機率的幫助已經很有限了。當信用分數為 500 分時（機率 $P \approx 0.5$ ）， $P(1 - P)$ 的變異數達到最大值，因此邊際效應的絕對值最大（-0.000891），當分數提升到 700 分，客戶已經相對安全時，再加 1 分的邊際效應就衰退了（-0.000783）

f.

```
hist(lasvegas$lvr, main="Histogram of LVR", xlab="Loan-to-Value Ratio")
```



```
cat("\n--- (f) Probabilities for LVR = 20, 80 ---\n")
```

```
##
## --- (f) Probabilities for LVR = 20, 80 ---
```

```

scenario_f <- data.frame(
  lvr = c(20, 80),
  credit = 600, amount = 2.5, rate = 8,
  insur = 0, ref = 0, arm = 0, term = 30
)

prob_lpm_f <- predict(lpm_model, newdata = scenario_f)
prob_logit_f <- predict(logit_model, newdata = scenario_f, type = "response")

results_f <- data.frame(LVR = c(20, 80), LPM_Prob = prob_lpm_f, Logit_Prob = prob_logit_f)
print(results_f)

```

```

##   LVR  LPM_Prob Logit_Prob
## 1  20 0.4116749  0.2349087
## 2  80 0.5091060  0.4086308

```

LVR = 20 是一個極端的例子（代表借款人自己出了 80% 的頭期款，貸款成數極低）在這種極端情況下，違約機率應該較小，但LPM 的預測機率只下降到了 41.1%，這依然是個偏高的違約機率，而Logit 模型因為具備 S 型的尾部特徵，它對這種極端條件的反應更為劇烈且合理，預測機率大幅下修到了 23.4%

g.

```
cat("\n--- (g) Percentage of Correct Predictions (Threshold = 0.5) ---\n")
```

```

##
## --- (g) Percentage of Correct Predictions (Threshold = 0.5) ---

```

```

# 取得全樣本預測機率
all_lpm_pred <- predict(lpm_model, newdata = lasvegas)
all_logit_pred <- predict(logit_model, newdata = lasvegas, type = "response")

# 判斷是否大於 0.5
lpm_class <- ifelse(all_lpm_pred > 0.5, 1, 0)
logit_class <- ifelse(all_logit_pred > 0.5, 1, 0)

# 計算正確率
lpm_accuracy <- mean(lpm_class == lasvegas$delinquent)
logit_accuracy <- mean(logit_class == lasvegas$delinquent)

cat("LPM Accuracy:   ", round(lpm_accuracy * 100, 2), "%\n")

```

```
## LPM Accuracy:    85.8 %
```

```
cat("Logit Accuracy: ", round(logit_accuracy * 100, 2), "%\n")
```

```
## Logit Accuracy:  85.4 %
```

h.

不能用 0.5，因為「看錯」的代價是極度不對稱的 如果銀行拒絕了一個好客戶（模型預測會違約，但其實不會），銀行的損失只是少賺了利息 如果銀行放款給一個壞客戶（模型預測不會違約 $P < 0.5$ ，但結果違約了），銀行的損失是賠掉龐大的本金 A Better Rule：因為放款給違約者的成本遠大於拒絕好客戶的機會成本，銀行的決策閾值應該要設得遠低於 0.5