

(10.18)

Consider the data file *mroz* on working wives. Use the 428 observations on married women who participate in the labor force. In this exercise, we examine the effectiveness of a parent's college education as an instrumental variable.

- Create two new variables. *MOTHERCOLL* is a dummy variable equaling one if *MOTHEREDUC* > 12, zero otherwise. Similarly, *FATHERCOLL* equals one if *FATHEREDUC* > 12 and zero otherwise. What percentage of parents have some college education in this sample?
- Find the correlations between *EDUC*, *MOTHERCOLL*, and *FATHERCOLL*. Are the magnitudes of these correlations important? Can you make a logical argument why *MOTHERCOLL* and *FATHERCOLL* might be better instruments than *MOTHEREDUC* and *FATHEREDUC*?
- Estimate the wage equation in Example 10.5 using *MOTHERCOLL* as the instrumental variable. What is the 95% interval estimate for the coefficient of *EDUC*?
- For the problem in part (c), estimate the first-stage equation. What is the value of the *F*-test statistic for the hypothesis that *MOTHERCOLL* has no effect on *EDUC*? Is *MOTHERCOLL* a strong instrument?
- Estimate the wage equation in Example 10.5 using *MOTHERCOLL* and *FATHERCOLL* as the instrumental variables. What is the 95% interval estimate for the coefficient of *EDUC*? Is it narrower or wider than the one in part (c)?
- For the problem in part (e), estimate the first-stage equation. Test the joint significance of *MOTHERCOLL* and *FATHERCOLL*. Do these instruments seem adequately strong?
- For the IV estimation in part (e), test the validity of the surplus instrument. What do you conclude?

(a)

```
> # 計算父母受過大學教育的百分比
> pct_mother <- mean(mroz_working$MOTHERCOLL) * 100
> pct_father <- mean(mroz_working$FATHERCOLL) * 100
> cat("母親大學教育比例:", pct_mother, "%\n")
母親大學教育比例: 12.14953 %
> cat("父親大學教育比例:", pct_father, "%\n")
父親大學教育比例: 11.68224 %
```

(b)

```
[1] "相關係數矩陣:"
> print(cor_matrix)
              educ MOTHERCOLL FATHERCOLL
educ          1.0000000  0.3594705  0.3984962
MOTHERCOLL    0.3594705  1.0000000  0.3545709
FATHERCOLL    0.3984962  0.3545709  1.0000000
```

相關係數:

EDUC 與 MOTHERCOLL: 0.3595

EDUC 與 FATHERCOLL: 0.3985

MOTHERCOLL 與 FATHERCOLL: 0.3546

這些相關係數的強度在計量分析中非常重要，作為工具變數（IV），*MOTHERCOLL* 和 *FATHERCOLL* 必須與內生變數 *EDUC* 有顯著的相關性。

而這兩個變數與教育程度的相關係數分別約為 0.36 與 0.40，屬於中等強度且顯著的相關。這意味著父母是否受過大學教育對子女的受教育年限有很強的預測力，初步滿足了工具變數的基本要求，能避免因相關性過低而導致的「弱工具變數（Weak Instruments）」問題。

為什麼使用虛擬變數 (MOTHERCOLL, FATHERCOLL) 可能比原始的受教育年限 (MOTHEREDUC, FATHEREDUC) 更好？論點如下：

降低測量誤差 (Reducing Measurement Error)：受訪者可能不記得父母確切的受教育年限（例如 11 年還是 12 年），但通常能準確記得父母是否「讀過大學」。使用「是否讀過大學」的二元分類 (Dummy) 能過濾掉微小的記憶誤差，提高數據的可靠性。

捕捉非線性階梯效應 (Non-linear Threshold Effect)：「大學學歷」本身具有一種門檻效應。父母一旦跨過大學門檻，對子女教育重視程度的提升，往往比單純多讀一年書（如 10 年變 11 年）的邊際影響更大，虛擬變數能更好地捕捉這種質變。

排除異常值的影響 (Robustness to Outliers)：原始數值變數（年限）可能會受到極端值的影響，而虛擬變數將所有大學以下學歷統一歸零、大學以上歸為一，這種處理方式在統計模型中更具穩健性。

(c)

```
> confint(iv_model_c, "educ", level = 0.95) # 95% 信賴區間
      2.5 %      97.5 %
educ -0.001219763 0.1532557
`
```

(d)

$$\text{educ} = 12.079 + 2.517 \cdot \text{MOTHERCOLL} + 0.056 \cdot \text{exper} - 0.002 \cdot (\text{exper}^2)$$

MOTHERCOLL 的係數為 2.517，代表在控制經驗因素後，母親擁有大學以上學歷會使子女的受教育年數顯著增加約 2.52 年。

```
> # --- (d) 第一階段回歸與 F 檢定 ---
> first_stage_d <- lm(educ ~ MOTHERCOLL + exper + I(exper^2), data = mroz_working)
> summary(first_stage_d)

Call:
lm(formula = educ ~ MOTHERCOLL + exper + I(exper^2), data = mroz_working)

Residuals:
    Min       1Q   Median       3Q      Max
-7.4267 -0.4826 -0.3731  1.0000  4.9353

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) 12.07904    0.303118   39.849 < 2e-16 ***
MOTHERCOLL   2.517068    0.315713    7.973 1.46e-14 ***
exper        0.056230    0.042101    1.336  0.182
I(exper^2)   -0.001956    0.001256   -1.557  0.120
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.133 on 424 degrees of freedom
Multiple R-squared:  0.1347,    Adjusted R-squared:  0.1285
F-statistic: 21.99 on 3 and 424 DF,  p-value: 2.965e-13
```

MOTHERCOLL 顯著性的檢定值：F-test statistic: 63.563、p-value: 1.455×10^{-14}

是的，這是一個強工具變數，p 值接近於 0，說明母親學歷與子女教育年數之間具極強的相關性。

```

> # F 檢定：MOTHERCOLL 是否為強工具變數
> linearHypothesis(first_stage_d, "MOTHERCOLL = 0")

Linear hypothesis test:
MOTHERCOLL = 0

Model 1: restricted model
Model 2: educ ~ MOTHERCOLL + exper + I(exper^2)

   Res.Df    RSS Df Sum of Sq    F    Pr(>F)
1     425 2219.2
2     424 1929.9   1    289.32 63.563 1.455e-14 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

(e)

```

> confint(iv_model_e, "educ", level = 0.95)
              2.5 %      97.5 %
educ 0.02751845 0.1481769
>

```

增加更多的有效工具變數（增加過度識別資訊）通常會增加估計值的精確度，從而縮小標準誤。

結論：這個區間會比 (c) 小題（僅使用一個工具變數時）更窄 (Narrower)。

理由：當我們同時使用母親與父親的學歷作為工具變數時，我們利用了更多的樣本資訊來捕捉 educ 的變異，這提高了估計的效率 (Efficiency)，使得估計值的變異性下降，因此信賴區間會收斂。

(f)

```

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept) 11.890259   0.290251  40.965 < 2e-16 ***
MOTHERCOLL   1.749947   0.322347   5.429 9.58e-08 ***
FATHERCOLL   2.186612   0.329917   6.628 1.04e-10 ***
exper        0.049149   0.040133   1.225  0.221
I(exper^2)   -0.001449   0.001199  -1.209  0.227
---

```

$$\text{educ} = 11.890 + 1.750 \cdot \text{MOTHERCOLL} + 2.187 \cdot \text{FATHERCOLL} + 0.049 \cdot \text{exper} - 0.001 \cdot (\text{exper}^2)$$

```

> # --- (f) 雙工具變數的第一階段 F 檢定 ---
> first_stage_f <- lm(educ ~ MOTHERCOLL + FATHERCOLL + exper + I(exper^2), data = mroz_working)
> linearHypothesis(first_stage_f, c("MOTHERCOLL = 0", "FATHERCOLL = 0"))

Linear hypothesis test:
MOTHERCOLL = 0
FATHERCOLL = 0

Model 1: restricted model
Model 2: educ ~ MOTHERCOLL + FATHERCOLL + exper + I(exper^2)

   Res.Df    RSS Df Sum of Sq    F    Pr(>F)
1     425 2219.2
2     423 1748.3  2     470.88 56.963 < 2.2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

針對 $H_0: \text{MOTHERCOLL} = 0, \text{FATHERCOLL} = 0$ 進行檢定：F-test statistic: 56.963、p 值： 2.2×10^{-16}

由於第一階段聯合 F 檢定的值 (56.963) 遠大於慣用的門檻值 10，這表明 MOTHERCOLL 與 FATHERCOLL 共同對 educ 具有強大的解釋力。因此，我們不需擔心弱工具變數 (Weak Instruments) 導致的偏誤問題，這組工具變數非常適當且強大。

(g)

```

Diagnostic tests:
              df1 df2 statistic p-value
Weak instruments  2 423     56.963 <2e-16 ***
Wu-Hausman       1 423      0.519  0.472
Sargan           1  NA      0.238  0.626
---

```

虛無假設 (H_0): 所有的工具變數都是外生的 (即 MOTHERCOLL 與 FATHERCOLL 皆為有效工具變數，且與誤差項不相關)。

p 值 (0.626) 遠大於 0.05，我們無法拒絕虛無假設。代表這兩個工具變數是有效的 (Valid)。多加入的工具變數與工資方程式的誤差項沒有顯著相關，因此模型設定是正確的。