

16.1

(a) Logit 模型下 $P(\text{AUTO}=1 \mid \text{DTIME}=1)$

代入線性指標： $\tilde{\gamma}_1 + \tilde{\gamma}_2 \cdot \text{DTIME} = -0.2376 + 0.5311(1) = 0.2935$

$P(\text{AUTO}=1 \mid \text{DTIME}=1) = \Lambda(0.2935) = \exp(0.2935) / [1 + \exp(0.2935)] = 1.3411 / 2.3411 \approx 0.5729$

(b) Probit 模型下 $P(\text{AUTO}=1 \mid \text{DTIME}=1)$

由 Example 16.4： $\beta_1 + \beta_2 \cdot \text{DTIME} = -0.0644 + 0.3000 \cdot \text{DTIME}$

代入 $\text{DTIME}=1$ ： $z = -0.0644 + 0.3000 = 0.2356$

查標準常態表： $\Phi(0.23) = 0.5910$ 、 $\Phi(0.24) = 0.5948$ ，內插得 $\Phi(0.2356) \approx 0.5931$

比較：Probit (0.5931) 與 Logit (0.5729) 結果非常接近，僅相差約 0.02；兩者也都接近 LPM 的估計 0.5551。三個模型在這個 DTIME 值下給出類似的預測。

(c) $\text{DTIME}=3$ 時，10 分鐘增量的邊際效應 (Logit vs. LPM)

Logit：邊際效應公式為 $\partial p / \partial \text{DTIME} = \Lambda(z)(1 - \Lambda(z)) \cdot \tilde{\gamma}_2$

$z = -0.2376 + 0.5311(3) = 1.3557$
 $\Lambda(1.3557) = 1 / (1 + e^{(-1.3557)}) = 1 / 1.2577 \approx 0.7951$
 $\Lambda(1 - \Lambda) = 0.7951 \times 0.2049 \approx 0.1629$
 邊際效應 = $0.1629 \times 0.5311 \approx 0.0866$

LPM：邊際效應為常數 = 0.0703 (係數本身)

比較：Logit 估計 (0.0866) 比 LPM (0.0703) 略大。LPM 不論 DTIME 為何都假設邊際效應固定；Logit 則允許邊際效應隨 DTIME 改變，在此點 ($\text{DTIME}=3$ ， $P \approx 0.80$) 較陡。

(d) $\text{DTIME}=-5$ 時，10 分鐘減量的邊際效應 (Logit vs. Probit)

「開車比公車多 50 分鐘」表示 $\text{BUSTIME} - \text{AUTOTIME} = -50$ ，所以 $\text{DTIME} = -5$ 。

Logit： $z = -0.2376 + 0.5311(-5) = -2.8931$
 $\Lambda(-2.8931) = 1 / (1 + e^{(2.8931)}) \approx 1 / 19.05 \approx 0.0525$
 $\Lambda(1 - \Lambda) = 0.0525 \times 0.9475 \approx 0.0497$
 邊際效應 = $0.0497 \times 0.5311 \approx 0.0264$

Probit：邊際效應 = $\varphi(\beta_1 + \beta_2 \cdot \text{DTIME}) \cdot \beta_2$

$z = -0.0644 + 0.3000(-5) = -1.5644$
 $\varphi(-1.5644) = (1/\sqrt{2\pi}) \cdot \exp(-1.5644^2/2) = 0.3989 \times \exp(-1.2237) \approx 0.3989 \times 0.2942 \approx 0.1174$
 邊際效應 = $0.1174 \times 0.3000 \approx 0.0352$

比較：Probit (0.0352) 比 Logit (0.0264) 略大。兩者數值都很小，因為在 $DTIME=-5$ 這個極端點， $P(AUTO)$ 已經非常接近 0 (約 0.05)。CDF 在尾端很平坦，所以 10 分鐘的變動對機率影響有限。Logit 的尾部下降較 Probit 慢但密度也較低，因此兩種模型雖在中央區域相似，在尾端可能差異略大。

16.4

(a) $x=1.5$ 時 $P(y=1)$

$$z = -1.836 + 3.021(1.5) = 2.6955 \quad \Lambda(2.6955) = 1/(1+e^{-(2.6955)}) = 1/(1+0.0675) \approx 0.9368$$

(b) 以 0.5 為門檻的預測

因為 $P(y=1|x=1.5) = 0.9368 > 0.5$ ，預測 $\hat{y} = 1$ 。實際 $y_1 = 1$ ，預測**正確**。

(c) $y_1=-1, y_2=2$ 時的概似函數值

計算三個指標：

- $z_1 = -1 + 2(1.5) = 2 \rightarrow \Lambda(2) = 0.8808$
- $z_2 = -1 + 2(0.6) = 0.2 \rightarrow \Lambda(0.2) = 0.5498$
- $z_3 = -1 + 2(0.7) = 0.4 \rightarrow \Lambda(0.4) = 0.5987$ ，所以 $1-\Lambda(0.4) = 0.4013$

$$L(-1, 2) = 0.8808 \times 0.5498 \times 0.4013 \approx 0.1943$$

比較 MLE：題目給 $\ln L(MLE) = -1.612$ ，所以 $L(MLE) = \exp(-1.612) \approx 0.1995$

$L(MLE) \approx 0.1995 > L(-1, 2) \approx 0.1943$ ，**MLE 較大**——這正符合 MLE 的定義：MLE 是使概似函數最大化的參數值，任何其他參數值都會得到較小 (或相等) 的概似值。

(d) Logit 模型的概似函數值是否一定介於 0 與 1 之間？

True (正確)。概似函數是若干項 $\Lambda(\cdot)$ 與 $[1-\Lambda(\cdot)]$ 的乘積 (依各觀察值 y_i 為 1 或 0 而定)。由於 logistic CDF 滿足 $0 < \Lambda(z) < 1$ (對所有有限的 z)，所以 $1-\Lambda(z)$ 也介於 0 與 1 之間。有限多個 $(0,1)$ 區間內數字的乘積，必然仍在 $(0,1)$ 區間內。

(e) Logit 模型的對數概似函數值是否一定為負？

True (正確)。由 (d)， $0 < L < 1$ (嚴格不等式，因為任何有限參數下 Λ 都不會剛好等於 0 或 1)。對 $(0,1)$ 區間內的數取對數，結果必為負數，即 $\ln L < 0$ 。

16.18

(a) LPM 模型結果解讀

LPM 採用 White HC1 穩健標準誤估計，結果顯示在 5% 顯著水準下，除了 amount 外其餘變數皆顯著。

t test of coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	0.68849128	0.22850643	3.0130	0.0026525	**
lvr	0.00162385	0.00067523	2.4049	0.0163601	*
ref	-0.05932367	0.02402561	-2.4692	0.0137098	*
insur	-0.48158489	0.03036944	-15.8575	< 2.2e-16	***
rate	0.03437614	0.00981944	3.5008	0.0004845	***
amount	0.02376801	0.01445089	1.6447	0.1003398	
credit	-0.00044190	0.00020728	-2.1319	0.0332620	*
term	-0.01261951	0.00355596	-3.5488	0.0004051	***
arm	0.12832392	0.02769325	4.6338	4.07e-06	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

- credit (-0.000442*): 信用分數每多 1 分，違約機率降低 0.044 個百分點，符號為負，合理。
- lvr (+0.00162*): 貸款成數愈高 (自備款愈少)，違約機率上升，符號為正，合理。
- rate (+0.0344***): 利率愈高，月付壓力愈大，違約機率上升，符號為正，合理。
- insur (-0.482***): 有買房貸保險的借款人違約率顯著較低 (保險可能反映借款人風險意識，或保險公司事先篩選過)。
- term (-0.0126***): 貸款期數愈長，違約率反而下降，可能因長期房貸的借款人月付較輕。
- arm (+0.128***): 浮動利率房貸違約率顯著高於固定利率 (受利率波動影響大)。
- ref (-0.0593*): 再融資貸款違約率較購屋貸款低，可能因再融資戶通常已有還款紀錄。

(b)

```
Call:
glm(formula = delinquent ~ lvr + ref + insur + rate + amount +
    credit + term + arm, family = binomial(link = "logit"), data = lasvegas)

Coefficients:
            Estimate Std. Error z value Pr(>|z|)
(Intercept)  1.665303   1.992157   0.836 0.403195
lvr          0.013519   0.008199   1.649 0.099164 .
ref         -0.525064   0.230491  -2.278 0.022725 *
insur       -3.122105   0.216906 -14.394 < 2e-16 ***
rate         0.308656   0.082771   3.729 0.000192 ***
amount       0.217606   0.113769   1.913 0.055786 .
credit      -0.003564   0.001933  -1.844 0.065232 .
term        -0.133037   0.034597  -3.845 0.000120 ***
arm          1.405649   0.371355   3.785 0.000154 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 998.03  on 999  degrees of freedom
Residual deviance: 666.29  on 991  degrees of freedom
AIC: 684.29

Number of Fisher Scoring iterations: 5
```

Logit 模型的所有變數符號與 LPM 完全一致，這代表模型結構穩健，無論用哪種函數形式都得到一致的方向性結論。在顯著性上：

- 強顯著 (***): insur、rate、term、arm — 兩個模型均高度顯著。
- 中度顯著 (*): ref 在兩個模型都顯著。
- 邊際顯著: lvr、amount、credit 在 Logit 中變成 0.05–0.10 之間 (.), 略低於 LPM 的顯著水準。這是正常現象，因為 Logit 的標準誤計算方式不同，且 MLE 對小樣本較保守。

Residual deviance 從 Null 的 998.03 大幅下降到 666.29，AIC=684.29，表示解釋變數整體對違約有顯著預測力。

結論：兩模型在「方向」與「主要顯著變數」上一致；數值差異反映 Logit 與 LPM 在函數形式上的本質不同 (Logit 係數作用於對數勝算比)，需透過邊際效應才能直接比較。

(C)

第 500 筆：實際未違約 (=0)。兩模型都給出低違約機率 (< 0.2)，預測方向正確。Logit 給出較低的機率 (0.13 vs 0.18)，這是因為在低違約區間 Logit 比 LPM 更保守、更接近 0。

第 1000 筆：實際未違約，但兩模型都預測高於 0.5 (會違約)，屬於 Type I 錯誤 (錯殺好客戶)。Logit 預測機率 (0.63) 反而比 LPM (0.58) 高。這個觀測值顯示模型並非完美，仍有預測失誤的個案；也提醒我們：以 0.5 為門檻不是萬靈丹。

(d)

Credit LPM 機率 Logit 機率

500 0.5533 0.4967

600 0.5091 0.4086

700 0.4649 0.3261

相似處：兩模型都顯示信用分數愈高、違約機率愈低，方向一致。

差異處：

1. LPM 機率呈完全線性下降 (每升 100 分減 4.42 個百分點)，這是 LPM 邊際效應為常數的必然結果。
2. Logit 機率非線性下降：500→600 下降 8.81 個百分點，600→700 下降 8.26 個百分點，下降幅度不均勻，反映非線性 S 曲線特性。
3. Logit 在低分區 (500) 更保守：LPM 給 0.55，Logit 只給 0.50；在高分區 (700) 也更保守：LPM 給 0.46，Logit 給 0.33。Logit 對極端值的縮減效果更明顯，這是它優於 LPM 之處。

直方圖顯示樣本中信用分數 500–700 涵蓋大多數借款人，因此這三個情境的預測都具實務代表性。

(e) 信用分數的邊際效應

Credit LPM 邊際效應 Logit 邊際效應

500	-0.000442	-0.000891
600	-0.000442	-0.000861
700	-0.000442	-0.000783

解讀：

- **LPM 邊際效應為常數** (-0.000442)，意指 credit 每增加 1 分，違約機率「不論信用分數高低」都同步下降 0.044 個百分點。這是 LPM 線性結構的限制。
- **Logit 邊際效應隨機率水準變動**，公式為 $\beta \cdot P(1-P)$ 。在 credit=500 時 $P \approx 0.50$ (最接近 0.5)， $P(1-P)$ 達最大值 0.25，因此邊際效應最大 (-0.000891)。隨著 credit 上升， P 漸減，邊際效應**逐漸縮小**，呈現「尾端收斂」現象。
- **政策意涵**：Logit 模型告訴銀行——信用分數從 500→501 比 700→701 對降低違約機率更有效。換言之，**鎖定信用分數中段 (瀕臨違約邊緣) 的客戶提供信用輔導**，比對信用優良戶錦上添花更具邊際效益。LPM 因假設常數邊際效應，無法揭示此重要的非線性結構。

(f) 不同貸款成數 (LVR) 的違約機率對比

固定 credit=600 與其他變數時：

LVR LPM 機率 Logit 機率

20%	0.4117	0.2349
80%	0.5091	0.4086

比較：

1. **方向一致**：兩模型都顯示槓桿愈高、違約機率愈大，符合金融常理。
2. **絕對差距**：LPM 顯示 LVR 從 20% 升到 80% 違約機率上升 9.74 個百分點 ($0.5091-0.4117$)；Logit 則顯示上升 17.37 個百分點 ($0.4086-0.2349$)，**Logit 估計的槓桿效應更大**。
3. **低槓桿情境下的差異最劇烈**：LPM 給 41% 高違約機率，Logit 只給 23%。LPM 高估了低風險客戶的違約率，這在實務上會導致過度謹慎、損失優良客戶。Logit 的非線性曲線在低風險區間下降較快，預測更合理。
4. **LVR 直方圖顯示樣本中借款人集中在 80% 附近 (極端右偏)**，20% 屬罕見低槓桿客戶——這也提醒我們對 20% 的預測屬樣本外推論，應審慎看待。

(g) 全樣本內預測準確率 (門檻 = 0.5)

- **LPM** : 85.8%

- Logit : 85.4%

兩模型準確率差異僅 0.4 個百分點，幾乎無分軒輊。這個結果看似令人滿意，但準確率指標有嚴重侷限：

樣本中違約戶為少數（基於資料背景大約 13–15%），即使將「所有客戶都預測為不違約」也能達到約 86% 的「準確率」。因此單看整體準確率會嚴重高估模型實際的鑑別力，必須搭配混淆矩陣中的**敏感度**（sensitivity, 找出違約者的能力）與**特異度**才能得到完整評估，這正是 (h) 要進一步檢驗的重點。

(h) 樣本外預測（0.5 門檻）的混淆矩陣與決策意涵

樣本外混淆矩陣（後 500 筆）：

	預測=0	預測=1
實際=0	406	27
實際=1	33	34

關鍵指標計算：

- 總準確率 = $(406+34)/500 = 88.0\%$
- 敏感度（抓出違約者比率） = $34/(33+34) = 50.7\%$
- 特異度（正確分辨好客戶比率） = $406/(406+27) = 93.8\%$
- Type I 錯誤（錯殺好客戶） = 27 筆
- Type II 錯誤（放過違約者） = 33 筆

為何 0.5 不是好的決策門檻？

雖然整體準確率高達 88%，但敏感度只有 50.7%——模型只抓到一半的違約戶。在 67 個真正會違約的客戶中，銀行用 0.5 門檻竟「審核通過」了其中 33 個！這在實務上是災難。

關鍵原因是**錯誤成本嚴重不對稱**：

- **Type I 錯誤成本**：錯殺一個好客戶，損失幾年期的利息淨利潤，例如貸款 25 萬 × 利率價差 2% × 30 年 ≈ 數萬美元。
- **Type II 錯誤成本**：放過一個違約戶，銀行可能損失大部分本金，例如 25 萬美元的房貸可能變成 5–10 萬美元的呆帳。

單一筆 Type II 錯誤的損失可能等於放掉 10–20 筆好客戶的利息收入。在這種成本結構下，銀行絕對不該用 0.5 作為門檻。